Le coût carbone d'une lecture d'archives par un modèle de langage

Le cas des notes de travail d'Alexandre Grothendieck

Michel Hua

Version de travail, 7 novembre 2026

Résumé

D'août à novembre 2026, un chercheur seul a utilisé des modèles de langage commerciaux pour transcrire 9 414 pages des notes de travail mathématiques d'Alexandre Grothendieck conservées à l'université de Montpellier, en rédiger des lectures modernisées, vérifier certains énoncés dans l'assistant de preuve Lean et préparer des articles. Cet article estime ce que ce travail a coûté en énergie et en gaz à effet de serre, à partir des jetons comptés par l'outil pendant six semaines et des durées d'exécution de l'intégration continue. L'estimation centrale est d'environ 110 kg d'équivalent CO_2 pour trois mois, dans une fourchette de 15 kg à 1,1 t. Un recoupement qui inclut la fabrication des serveurs donne cinq à neuf fois plus. Presque tout vient de l'inférence, et surtout de la relecture de longs contextes à chaque tour. L'article explique d'où vient cette dépense, la compare à l'empreinte professionnelle des personnes qui éditent ce corpus et discute l'effet rebond.

Mots-clés : humanités numériques, modèles de langage, empreinte carbone, effet rebond, manuscrits de Grothendieck

Abstract

The carbon cost of reading an archive with a language model. Between August and November 2026, a single researcher used commercial large language models to transcribe 9,414 pages of Alexandre Grothendieck's mathematical working notes held at the University of Montpellier, to write modernised readings of them, to check some of their statements in the Lean proof assistant and to draft articles. This paper estimates what that work cost in energy and greenhouse-gas emissions, from the token counts recorded by the tool over six weeks and the run times of the continuous-integration service. The central estimate is about 110 kg of CO_2e for three months, within a range of 15 kg to 1.1 t. A cross-check that includes the manufacture of the servers gives five to nine times more. Almost all of it comes from model inference, and most of that from re-reading long contexts at every turn. The paper explains where this energy goes, compares the figure with the professional footprint of the people who edit the corpus, and discusses the rebound effect.

Keywords: digital humanities, large language models, carbon footprint, rebound effect, Grothendieck manuscripts

1 Pourquoi mesurer

En 2018, The Shift Project estimait que la part du numérique dans les émissions mondiales de gaz à effet de serre était passée de 2,5 % en 2013 à 3,7 %, et que sa consommation d'énergie augmentait d'environ 9 % par an (The Shift Project, 2018). Son rapport de 2025 sur l'intelligence artificielle et les centres de données conclut que, si les tendances actuelles se poursuivent, les centres de données pourraient émettre jusqu'à 920 Mt CO_2e par an en 2030 (The Shift Project, 2025). Le coût environnemental des modèles de langage a été mesuré pour leur entraînement

(Luccioni et al., 2023 ; Morand et al., 2026), et l'analyse du cycle de vie a servi à faire apparaître les impacts cachés des applications de l'IA, y compris de celles qui prétendent servir l'environnement (Ligozat et al., 2022). Un numéro de *Humanités numériques* a porté la question de la sobriété numérique dans les sciences humaines (Baillot and Ligozat, 2025).

On connaît mal, en revanche, le coût d'un usage savant concret : un projet, un corpus, du début à la fin. La question a été posée directement à ce projet. Quand l'auteur a demandé aux gardiens d'une archive mathématique l'autorisation de lire leurs documents avec ces outils, la réponse de l'ACNB s'est opposée à l'usage d'une IA commerciale sur des archives savantes. L'objection était éthique autant qu'environnementale. Sa part environnementale peut se mesurer ; c'est ce que fait cet article.

2 Le projet

Le fonds Grothendieck de l'université de Montpellier compte 178 cotes et 16 074 pages annoncées. Entre le premier dépôt du projet, le 7 août 2026, et le 7 novembre, 164 de ces cotes ont été transcrites, en 638 lots de vingt pages, soit 9 414 pages au 18 octobre. Chacune de ces cotes a reçu une lecture modernisée, qui reprend ses mathématiques dans les notations et le vocabulaire actuels. Certains énoncés ont été vérifiés dans l'assistant de preuve Lean : au 7 novembre, le dossier `lean/` du dépôt compte 6 685 théorèmes et lemmes répartis dans 296 fichiers. Le projet a aussi préparé 21 brouillons d'articles, dont celui-ci, et lu quelques autres archives mathématiques. Tout ce travail a été fait avec trois modèles de l'entreprise Anthropic, Claude Opus 5.5, Sonnet 5.5 et Haiku 5.5, au moyen de l'outil Claude Code. Le dépôt public du projet en garde l'historique : 2 482 commits au 7 novembre.

3 Comment un modèle de langage dépense de l'énergie

Cette section s'adresse aux lecteurs qui n'ont pas de formation en informatique. Elle explique les quelques mécanismes qui déterminent la dépense d'énergie d'un modèle de langage, et sur lesquels reposent les choix de méthode de la section 5.

Paramètres et opérations. Un modèle de langage est un très grand ensemble de nombres, ses *paramètres*, fixés pendant l'entraînement. Il ne manipule pas des mots mais des *jetons* (*tokens*), des fragments de mots. Pour traiter un jeton, il fait passer ce jeton à travers toutes ses couches, ce qui demande environ deux opérations par paramètre, une multiplication et une addition. Un modèle de N paramètres effectue ainsi environ $2N$ opérations par jeton, auxquelles s'ajoute un terme qui croît avec la longueur du texte déjà présent, le *contexte* (Kaplan et al., 2020, éq. 2.2). Pour les grands modèles, ce second terme pèse peu dans le calcul (Pope et al., 2023). Un modèle de cent milliards de paramètres fait donc de l'ordre de 2×10^{11} opérations pour chaque jeton qu'il lit ou qu'il écrit. Les fournisseurs ne publient pas la taille de leurs modèles les plus récents, et c'est la première raison pour laquelle on ne peut pas calculer leur consommation directement.

Lire et écrire. Une requête se déroule en deux phases. Dans la première, le modèle lit tout le texte qu'on lui soumet (le *préremplissage*, *prefill*). Tous les jetons de ce texte sont connus d'avance : la machine peut les traiter ensemble, en parallèle, et ses unités de calcul travaillent à plein. Dans la seconde, le modèle écrit sa réponse (le *décodage*). Chaque nouveau jeton dépend du précédent, si bien qu'il faut les produire un par un. À chaque pas, la machine doit relire depuis sa mémoire tous les paramètres du modèle et tout ce qu'elle garde du contexte, pour un calcul très court. Le décodage est donc limité par le débit de la mémoire, non par la puissance de calcul. L'étude de Patel et al. (2024), menée sur des grappes de processeurs graphiques en production, mesure cette différence : la phase de lecture est « intensive en calcul » et sa puissance électrique augmente avec le nombre de requêtes traitées ensemble, tandis que la phase d'écriture est limitée

par la mémoire et sous-utilise les unités de calcul. Brider la puissance de ces processeurs de 700 à 350 W ne ralentit presque pas l'écriture, alors que la lecture y est très sensible.

Le cache des clés et des valeurs. Pour écrire chaque nouveau jeton, le modèle doit tenir compte de tous les jetons précédents. Il ne les recalcule pas : il conserve, pour chaque couche, deux tableaux de nombres qui les résument, les *clés* et les *valeurs*, ce qu'on appelle le cache KV. Ce cache évite de refaire le calcul, mais il occupe de la mémoire et il faut le relire à chaque pas. Pope et al. (2023) donnent un exemple : pour un modèle de plus de 500 milliards de paramètres, 512 requêtes simultanées et des contextes de 2 048 jetons, le cache KV atteint 3 téraoctets, trois fois la taille du modèle, et il doit être chargé depuis la mémoire pour chaque jeton produit, pendant que les unités de calcul restent presque inactives.

Les fournisseurs proposent en outre de garder ce résumé d'une requête à l'autre (*prompt caching*). Quand une conversation reprend avec le même début, le modèle n'a pas à relire ce début : il récupère son cache. Une lecture depuis le cache coûte donc beaucoup moins qu'une relecture complète, puisqu'elle évite les $2N$ opérations par jeton du préremplissage. Elle n'est pas gratuite pour autant : le cache doit être stocké, transféré vers le processeur qui traite la requête, puis relu à chaque jeton écrit, comme on vient de le voir. Le fournisseur ne publie pas comment son cache est mis en œuvre ; ce qui précède décrit le principe général, non son infrastructure.

Pourquoi le contexte domine dans un usage agentique. Un agent comme celui utilisé ici (Claude Code) travaille par tours : à chaque tour, il envoie au modèle toute la conversation depuis le début, les fichiers lus, les résultats des commandes, puis il reçoit une réponse courte, qui s'ajoute au contexte du tour suivant (figure 1). Le contexte grandit au fil de la session, et il est relu à chaque tour. Dans ce projet, sur la fenêtre mesurée, chaque appel à Opus 5.5 a relu en moyenne environ 515 000 jetons depuis le cache, en a écrit environ 5 200 nouveaux dans le cache et a produit environ 680 jetons de réponse. Pour un jeton écrit, le modèle en a donc relu plus de 700. Même à un centième du coût d'un jeton écrit, ces relectures pèsent plus que tout le reste (section 6).

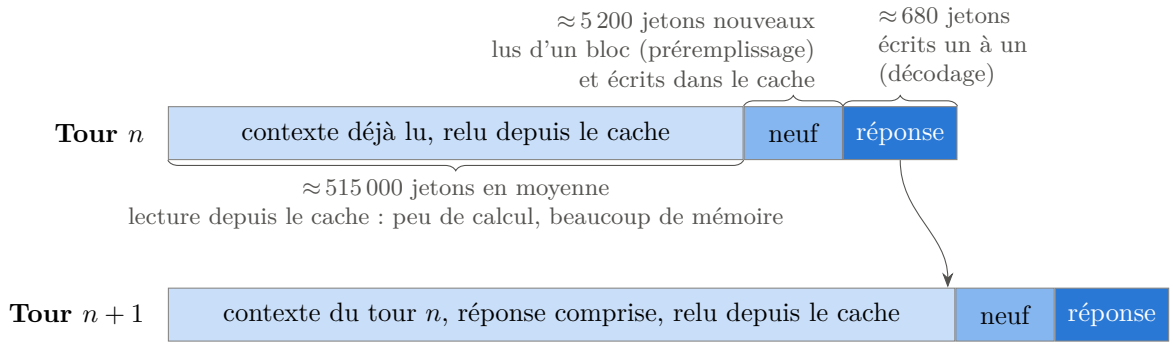


FIGURE 1 – Un tour d'agent. À chaque appel, le modèle relit tout le contexte accumulé (en pâle), lit et met en cache les éléments nouveaux (le message, le fichier ou le résultat de commande qui vient d'arriver), puis écrit sa réponse, qui entre dans le contexte du tour suivant. Les nombres sont les moyennes par appel à Opus 5.5 sur la fenêtre mesurée (24 septembre – 7 novembre 2026). Les longueurs ne sont pas à l'échelle : à l'échelle, la partie pâle serait environ cent fois plus longue que la partie « neuf ».

Traitement par lots et taux d'occupation. Un serveur ne traite pas une requête à la fois : il en regroupe plusieurs dans un même lot, ce qui permet de relire une seule fois les paramètres pour toutes les requêtes du lot. Plus le lot est grand, plus l'énergie par jeton baisse, jusqu'à ce que la mémoire soit pleine (Patel et al., 2024). Pope et al. (2023) montrent qu'un petit lot donne

une faible utilisation des unités de calcul et un coût par jeton plus élevé. L'énergie dépensée pour un jeton dépend donc de l'occupation des machines au moment de la requête, que l'utilisateur ne voit pas. Les machines tenues en réserve et inactives consomment aussi ; la mesure publiée par Google pour son assistant Gemini les compte (Elsworth et al., 2025).

Mesures publiées. Luccioni et al. (2024) ont mesuré l'énergie de l'inférence pour 88 modèles et dix tâches, sur des modèles allant jusqu'à 11 milliards de paramètres. La génération de texte y consomme en moyenne environ 0,05 kWh pour 1 000 requêtes, plus de dix fois la classification de textes, et les modèles génératifs polyvalents coûtent des ordres de grandeur de plus que les modèles spécialisés pour une même tâche. Les modèles utilisés dans ce projet sont beaucoup plus grands et leurs requêtes beaucoup plus longues, de sorte que ces mesures ne s'appliquent pas telles quelles ; elles donnent un plancher et montrent l'écart entre usages.

Du serveur au bâtiment. L'énergie consommée par les processeurs n'est qu'une partie de celle du centre de données. Il faut y ajouter le refroidissement, l'alimentation électrique et les pertes, que mesure l'indicateur d'efficacité énergétique (PUE, *power usage effectiveness*) : le rapport entre l'énergie totale du bâtiment et celle des équipements informatiques. La méthode Cloud Carbon Footprint retient 1,135 pour Amazon Web Services, 1,1 pour Google Cloud et 1,185 pour Microsoft Azure (Cloud Carbon Footprint, 2026). Les fourchettes de cet article sont données au niveau du centre de données, ces pertes comprises.

De l'énergie au carbone. Un kilowattheure n'émet pas partout la même quantité de gaz à effet de serre. L'intensité carbone du réseau électrique varie selon le mode de production : de l'ordre de 60 g CO_2e par kWh en France, très nucléarisée, contre 475 g en moyenne mondiale, selon les valeurs retenues par De Paepe et al. (2024). Le fournisseur ne publie pas où se trouvent les centres de données qui ont servi ce projet, d'où la fourchette de la section 5.

La fabrication. Les serveurs, les processeurs graphiques et les bâtiments ont été fabriqués, et cette fabrication a émis des gaz à effet de serre avant toute utilisation. L'analyse du cycle de vie demande d'en compter une part, ainsi que la fin de vie du matériel (Ligozat et al., 2022). Pour l'entraînement du modèle BLOOM, Luccioni et al. (2023) trouvent 24,7 t CO_2e si l'on ne compte que la consommation électrique dynamique, et 50,5 t si l'on ajoute la fabrication du matériel et la consommation des machines au repos. Notre estimation principale ne compte que l'électricité ; le recoupement de la section 6 donne une idée de ce qu'ajoute la fabrication.

Le prix comme indicateur. Faute de chiffres d'énergie, on peut pondérer les jetons par leur prix, en supposant que le prix suit le coût du calcul. C'est une approximation grossière. Le prix comprend la marge du fournisseur et reflète sa stratégie commerciale. On le voit dans la grille tarifaire elle-même : la lecture depuis le cache est facturée 5 % du prix d'un jeton d'entrée sur Opus 5.5 et Sonnet 5.5, mais 10 % sur Haiku 5.5, et Haiku facture cinq fois plus cher les requêtes de plus de 100 000 jetons (Anthropic, 2026). Le second écart traduit sans doute un coût réel des longs contextes ; le premier ressemble davantage à un choix commercial. Le prix ne dit rien non plus de l'occupation des machines ni de l'électricité du lieu. Il donne cependant un ordre de grandeur cohérent pour comparer entre eux les types de jetons d'un même modèle, et c'est l'usage qu'en fait cet article.

4 Données

Usage des modèles. L'outil (Claude Code) enregistre une ligne par appel au modèle, avec le nombre de jetons d'entrée, de sortie et de cache. Il efface ses historiques après un délai réglable, fixé à 14 jours pendant le projet. Les enregistrements conservés couvrent la période du

24 septembre au 7 novembre 2026 : 44 des 92 jours du projet, environ six de ses treize semaines. Dédoublonnés par message, ils donnent les totaux du tableau 1. Haiku 5.5 n'a servi que 23 fois, du 2 au 7 novembre ; sa part est négligeable. La durée de conservation a été allongée le 7 novembre, si bien que la suite du projet sera mesurée et non extrapolée.

Modèle	Appels	Sortie	Écritures en cache	Lectures en cache
Opus 5.5	15 556	10,53 M	81,4 M	8,01 G
Sonnet 5.5	1 584	1,62 M	16,0 M	0,699 G
Haiku 5.5	23	0,023 M	0,211 M	0,000 2 G

Table 1 – Jetons enregistrés du 24 septembre au 7 novembre 2026, dédoublonnés par message (M : millions, G : milliards). Les jetons d'entrée hors cache sont négligeables.

Intégration continue. Le dépôt du projet avait exécuté 2 378 flux de travail GitHub Actions au 7 novembre. L'API de GitHub donne encore la durée de chaque tâche pour 1 541 d'entre eux, soit 2 769 tâches ; pour les autres, surtout les plus anciens ou les exécutions annulées, elle n'en donne plus. Les tâches mesurées ont tourné 271,5 heures (298 heures si l'on arrondit chaque tâche à la minute supérieure, comme le fait la facturation). Le déploiement du site, qui comprend la mise en forme des transcriptions et la compilation de leurs PDF, en prend 260 heures, soit 96 % ; la vérification des preuves Lean avec la bibliothèque mathlib n'en prend que 11. Par mois : 4 heures en août, 54 en septembre, 203 en octobre et 11 dans la première semaine de novembre. Si les exécutions sans données avaient la durée moyenne des autres, il faudrait ajouter au plus 150 heures ; on retient 270 à 420 heures-machine, 300 au centre. Un exécuteur standard de GitHub pour un dépôt public est une machine virtuelle à 4 processeurs virtuels et 16 Go de mémoire, hébergée sur Microsoft Azure (ou, pour certaines tâches Linux, sur Amazon Web Services) (GitHub, 2026).

Autres postes. L'ordinateur portable de l'auteur, l'hébergement du site du projet et le stockage des fac-similés, qui sont lus en direct depuis Montpellier et non copiés.

5 Méthode

Le fournisseur ne publie pas l'énergie consommée par jeton. On l'encadre donc, en suivant la démarche des évaluations publiées (Luccioni et al., 2023 ; Ligozat et al., 2022).

1. *Pondération.* Les jetons sont pondérés par leur prix catalogue rapporté à celui d'un jeton de sortie, comme indicateur du calcul (section 3). Pour Opus 5.5 et Sonnet 5.5, les rapports publiés sont 1 pour la sortie, 0,25 pour une écriture en cache de cinq minutes (0,40 pour une heure) et 0,01 pour une lecture en cache ; pour Haiku 5.5, 1, 0,25 (0,40) et 0,02 (Anthropic, 2026). Avec les rapports à cinq minutes, la fenêtre mesurée représente environ 124 M de jetons équivalent-sortie (111 M sur Opus, 12,6 M sur Sonnet, moins de 0,1 M sur Haiku). Les jetons de Haiku sont comptés comme ceux des grands modèles, ce qui les surestime sans changer le total. Pour tenir compte de la grossièreté de l'indicateur, on reporte dans les fourchettes une pondération haute : écritures à une heure et lectures en cache à 0,02, le rapport qui vaut pour la plupart des autres modèles, ce qui donne environ 225 M.
2. *Énergie par jeton.* Entre 0,5 et 5 mWh par jeton équivalent-sortie, au niveau du centre de données (refroidissement, capacité inactive et autres pertes comprises). Le bas de la fourchette correspond aux chiffres publics pour des modèles de taille moyenne. Google a mesuré 0,24 Wh pour la requête textuelle médiane de son assistant Gemini en mai 2025,

machines inactives et pertes du centre de données comprises (Elsworth et al., 2025). Epoch AI estime à environ 0,3 Wh une requête typique à GPT-4o, en supposant 500 jetons de sortie, soit environ 0,6 mWh par jeton de sortie (You, 2025). Le haut de la fourchette tient compte d'un modèle de pointe plus grand et des longs contextes : selon Epoch AI, une requête de 10 000 jetons d'entrée demande environ 2,5 Wh et une de 100 000 jetons environ 40 Wh, quand l'entrée n'est pas en cache. [**À vérifier : un chiffre d'énergie du fournisseur, s'il accepte d'en donner un**].

3. *Intensité carbone.* Entre 0,2 et 0,4 kg CO_2e/kWh, l'intensité du réseau électrique. Les pertes sont déjà dans le chiffre d'énergie. Les enregistrements de l'outil ont un champ pour la région d'inférence, mais il vaut « global » ou « not_available » pour tous les appels de la fenêtre : la région des centres de données qui ont servi le projet n'est pas connue.
4. *Extrapolation.* Les semaines non mesurées ont été moins chargées que les semaines mesurées. Le dépôt a reçu 321 commits avant le 24 septembre et 1 996 après, et 219 000 lignes de transcription avant contre 432 000 après ; aucun fichier Lean n'avait été ajouté avant cette date. Mettre la fenêtre à l'échelle de la part des lignes de transcription donne un facteur 1,5, celle des commits 1,2, et la seule durée 2,1. On retient 1,2 à 2,5, avec 1,5 comme valeur centrale. [**À vérifier : une mesure directe des premières semaines, si le compte en garde un historique**].
5. *Intégration continue.* On applique les coefficients de la méthode Cloud Carbon Footprint pour Azure (Cloud Carbon Footprint, 2026) : de 0,78 W par processeur virtuel au repos à 3,76 W à pleine charge, 0,392 W par gigaoctet de mémoire et un PUE de 1,185. La puissance moyenne d'un processeur s'y calcule comme le minimum plus le taux d'utilisation fois l'écart entre maximum et minimum ; la méthode retient 50 % d'utilisation quand le taux réel est inconnu. Les compilations du site et des preuves occupent fortement les processeurs : on suppose donc une utilisation entre 50 et 100 %, avec 75 % comme valeur centrale. Pour 4 processeurs virtuels et 16 Go, cela donne 18 à 25 W par exécuteur (22 W au centre), PUE compris, et 5 à 10 kWh pour 270 à 420 heures-machine. Ces coefficients ne comptent ni le réseau ni le stockage, et la part de fabrication que la méthode estime à part n'est pas incluse. Benaben et al. (2024) décrivent comment un facteur par heure-cœur se calcule pour un centre de calcul.
6. *Estimation centrale.* Les valeurs centrales sont la pondération au prix catalogue, 2 mWh par jeton équivalent-sortie, 0,3 kg CO_2e/kWh et un facteur 1,5. Elles se situent vers le milieu de chaque fourchette et n'ont pas de sens statistique. Les bornes basse et haute de chaque fourchette combinent les extrêmes de tous les facteurs.
7. *Périmètre.* L'estimation principale ne compte que l'inférence et son électricité. La fabrication du matériel, que Ligozat et al. (2022) demandent de compter, intervient par un recoupement (section 6). L'entraînement des modèles est laissé de côté.

6 Résultats

L'inférence domine (figure 2), et en son sein les lectures en cache (figure 3). À chaque tour d'une session, tout le contexte est relu (section 3), et les longues sessions sur de longues transcriptions multiplient ce coût. Avec les pondérations au prix catalogue, les lectures en cache font 70 % des jetons équivalent-sortie, les écritures en cache 20 % et la sortie 10 %. Avec la pondération haute, les lectures montent à 77 %. Elles ne cesseraient de dominer que si une lecture en cache coûtait en énergie bien moins de 1 % d'un jeton de sortie. C'est là qu'une démarche de sobriété agirait d'abord : des contextes plus courts, des modèles plus petits pour les tâches simples, moins de reconstructions du site.

Poste	Énergie (kWh)	Carbone (kg CO_2e)
Inférence, fenêtre mesurée (6 semaines)	62 – 1 100	12 – 450
valeur centrale	250	74
Inférence, projet entier (×1,2 à ×2,5)	74 – 2 800	15 – 1 100
valeur centrale (×1,5)	370	110
Intégration continue (270 à 420 heures-machine)	5 – 10	1,0 – 4,2
Ordinateur portable, site web	15 – 30	< 5
Total, estimation centrale	≈ 400	≈ 110

TABLE 2 – Première estimation pour l'ensemble du projet, du 7 août au 7 novembre 2026. Des fourchettes, non des intervalles de confiance. Le carbone de l'ordinateur portable est celui de son électricité sur le réseau français ; sa fabrication est exclue.

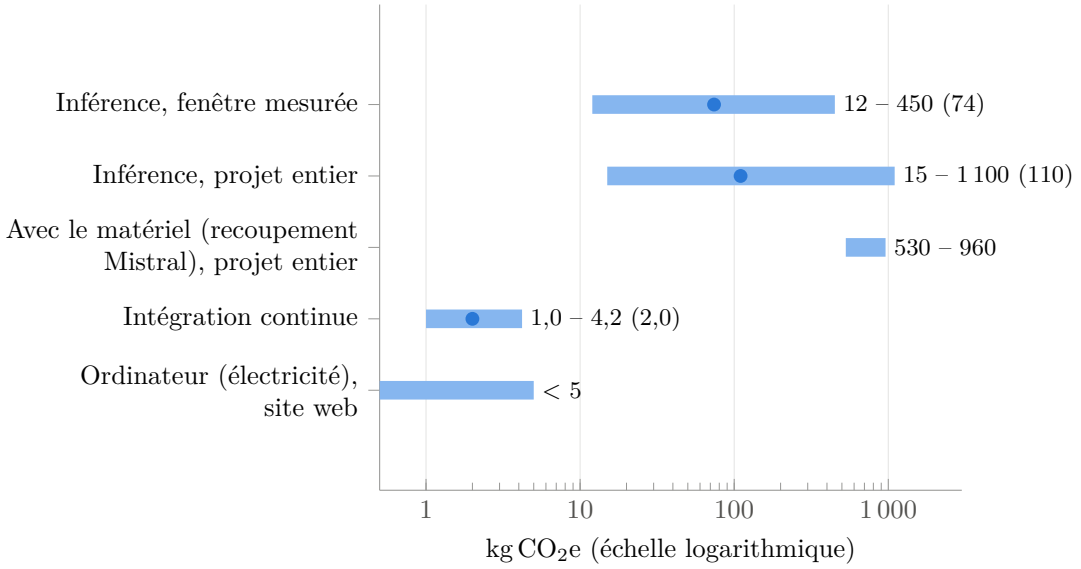


FIGURE 2 – Carbone estimé par poste. Les barres pâles sont les fourchettes, les points les valeurs centrales, rappelées entre parenthèses. Le recoupement Mistral compte la fabrication des serveurs et n'a pas de valeur centrale propre. L'échelle est logarithmique : chaque graduation vaut dix fois la précédente.

Un recoupement qui inclut le matériel. L'analyse du cycle de vie de Mistral AI pour son modèle Mistral Large 2, menée avec Carbone 4 et l'ADEME, donne l'impact marginal de l'inférence pour une réponse de 400 jetons de son assistant : 1,14 g CO_2e et 45 mL d'eau (Mistral AI, 2025). Ce chiffre compte la fabrication des serveurs et toute leur électricité, pas seulement celle des accélérateurs. Appliqué par jeton équivalent-sortie, il donne 0,35 à 0,64 t pour la fenêtre mesurée, et 0,53 à 0,96 t pour le projet avec le facteur central, soit cinq à neuf fois l'estimation centrale fondée sur la seule énergie. Les deux chiffres diffèrent par le périmètre, le modèle, la longueur des réponses et le réseau électrique ; l'écart ne remet donc pas en cause la fourchette d'énergie. Il suggère que l'estimation fondée sur l'énergie ne représente que la partie basse de l'empreinte complète, et que fabriquer le matériel pèse peut-être autant que le faire fonctionner, ou davantage.

Les sous-agents effacés. Le projet confie une grande partie de son travail à des *sous-agents* : des instances du modèle que la session principale lance pour une tâche, une transcription ou une preuve par exemple, et qui tiennent leur propre historique. Ces historiques ont été effacés au

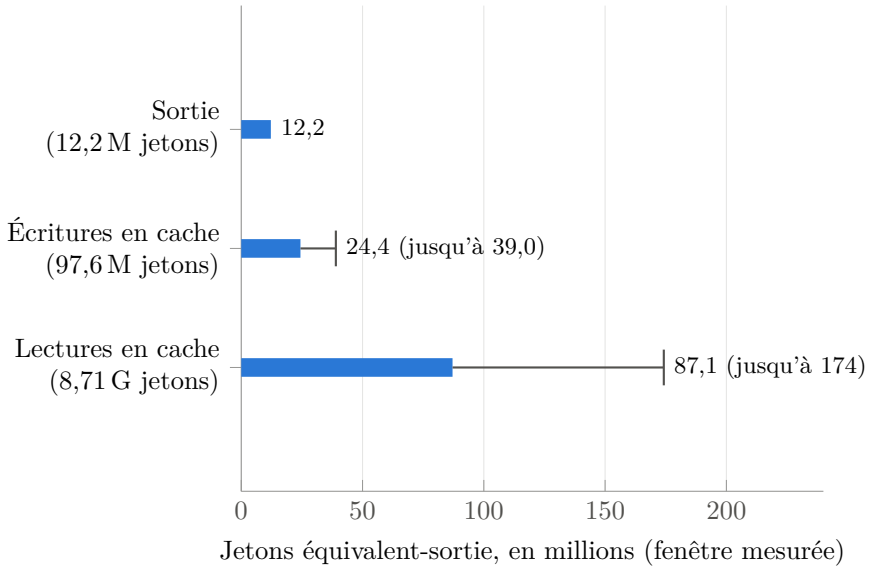


FIGURE 3 – Jetons enregistrés sur Opus 5.5, Sonnet 5.5 et Haiku 5.5, par type, pondérés par leur prix catalogue rapporté à un jeton de sortie. Les barres utilisent les rapports au prix catalogue (1, 0,25, 0,01) ; les traits fins vont jusqu'à la pondération haute (écritures à une heure à 0,40, lectures à 0,02). Les nombres bruts sont sous chaque libellé. Les lectures en cache font 99 % des jetons bruts et 70 à 77 % du total pondéré.

bout de quatorze jours, comme les autres, et seuls subsistent ceux des sous-agents lancés à partir du 1er novembre. Des 478 sous-agents lancés plus tôt dans la fenêtre, la session principale garde la consigne et le modèle et, pour 180 d'entre eux, l'avis de fin, qui donne le nombre d'appels d'outils et la taille finale du contexte. Les totaux du tableau 1 ne comptent pas leurs jetons. On peut les estimer à partir de ces deux nombres, en supposant que le contexte grandit jusqu'à sa taille finale et qu'il est relu à chaque appel. Sur les 24 sous-agents dont on a à la fois l'historique et l'avis de fin, les jetons comptés valent 0,67 à 1,87 fois ceux de ce modèle, 1,22 fois en valeur médiane ; on applique ce facteur, et un sous-agent sans avis de fin reçoit la valeur médiane de son activité. L'estimation ajoute environ 62 M de jetons équivalent-sortie (34 à 170 M) aux 133 M recomptés le soir du 7 novembre, soit à peu près moitié plus. L'estimation principale des tableaux 1 et 2 ne compte pas ces jetons ; les y ajouter porterait sa valeur centrale pour le projet d'environ 110 à 175 kg CO_2e.

Par activité. Pour répartir la dépense, chaque appel au modèle de la session principale a été rattaché à une activité d'après ce que faisait la session à ce moment : les compétences (*skills*) qu'elle appelait, les fichiers qu'elle écrivait, modifiait ou lisait, les commandes qu'elle lançait et les consignes qu'elle donnait aux sous-agents. Un sous-agent est classé de la même manière, d'après sa consigne et ses propres appels d'outils. Le classement est heuristique : une session qui relit une transcription pour écrire un article peut compter pour l'une ou pour l'autre. Les tours sans signal net, consacrés à lancer et à suivre les sous-agents, à lire les tickets du dépôt ou à la correspondance, sont rangés sous « pilotage ». Le tableau 3 donne le résultat pour la fenêtre mesurée, sous-agents effacés compris ; le calcul est dans le fichier `computations/carbon/activity.py` du dépôt, et sa sortie dans `activity.txt`.

Articles, site et pilotage font ensemble environ la moitié du total, à peu près autant que la transcription, les lectures modernisées, les preuves et les autres archives réunies. Rapportée aux 6 898 pages dont le lot a été déposé dans la fenêtre (d'après les marques de page des fichiers), la transcription coûte environ 3 g CO_2e par page (0,3 à 23 g). Ce chiffre est sans doute bas, puisque 121 des 170 sous-agents de transcription effacés n'ont pas laissé d'avis de fin et ont reçu

Activité	Part des jetons pondérés	kg CO_2e	
		centre	fourchette
Transcription du fonds Grothendieck	16 %	19	2 – 160
Lectures modernisées	4 %	5	0,6 – 44
Preuves Lean	16 %	19	3 – 140
Autres archives	12 %	14	2 – 91
Articles	18 %	21	3 – 130
Trouvailles et relecture	2 %	2,5	0,4 – 18
Site	15 %	17	3 – 110
Pilotage	16 %	18	3 – 140
Total	100 %	117	17 – 830

Table 3 – Répartition par activité de l'inférence sur la fenêtre mesurée (24 septembre – 7 novembre 2026), avec les mêmes facteurs que le tableau 2, sans extrapolation au projet entier. Les jetons comprennent les 133 M mesurés et les 62 M estimés pour les sous-agents dont l'historique a été effacé. Trois sessions sans rapport avec le projet, lancées depuis le même dossier (0,4 M de jetons), sont exclues. « Trouvailles et relecture » désigne la recherche, dans la littérature publiée, des résultats des notes qui n'y figureraient pas, et sa vérification.

une valeur médiane. Une seconde estimation part des mesures faites le 25 septembre sur douze passes de transcription, reprises sur la page de méthode du site : 25 M de jetons de contexte et 75 000 jetons écrits par lot de vingt pages. En répartissant ce contexte entre écritures et lectures en cache comme dans les sessions de transcription mesurées, on obtient environ 20 000 jetons équivalent-sortie et 12 g CO_2e par page (2 à 69 g). On retiendra 3 à 12 g par page en valeur centrale. Les 6 685 théorèmes et lemmes Lean, tous écrits dans la fenêtre, puisque aucun fichier Lean n'existait avant le 24 septembre, coûtent environ 3 g chacun (0,4 à 21 g), contributions à la bibliothèque mathlib comprises.

7 Ordres de grandeur : les éditeurs du corpus

Le chiffre ne dit pas grand-chose à lui seul. Un point de comparaison est l'empreinte professionnelle des chercheurs des laboratoires français, mesurée avec l'outil GES 1point5. Une première analyse de plus d'une centaine de laboratoires trouve en moyenne 3,6 t CO_2e par an et par membre, ou 3,1 t sans les effets de l'aviation autres que son CO_2 (Mariette et al., 2022). Une étude ultérieure de 108 laboratoires, qui ajoute les achats, trouve une moyenne de 6,2 t par personne (médiane 5,6 t), dont la moitié environ pour les achats (De Paepe et al., 2024). Ces études ne publient pas de chiffre par personne pour les mathématiques ou l'histoire. De Paepe et al. (2024) distinguent seulement trois grands domaines : leurs laboratoires de sciences humaines et sociales ont une intensité carbone des achats plus faible (0,22 kg CO_2e par euro contre 0,31 en moyenne), et une réduction de 6 % de leurs émissions totales y représente 0,2 t par personne, ce qui situe ces émissions autour de 3 t par personne et par an (calcul de l'auteur). Les auteurs préviennent que ce résultat repose sur 10 inventaires de 8 laboratoires seulement. L'enseignement supérieur et la recherche devront réduire fortement ces empreintes pour tenir les objectifs climatiques (Ligozat et al., 2024). On retient 2 à 5 t par an pour un chercheur, autour de la moyenne de Mariette et al. (2022). [**À vérifier : des chiffres par personne pour les laboratoires de mathématiques, s'ils existent dans la base GES 1point5 ; 1 à 3 t pour un doctorant reste une hypothèse de travail**].

Les éditions faites à la main couvrent 20 cotes et 5 129 pages, établies par une dizaine de personnes nommées : M. Künzer, J. Malgoire et G. Maltsiniotis pour *Les Dérivateurs* (2 135

pages) ; G. Maltsiniotis pour *À la poursuite des champs* I (837 pages) ; J. Malgoire pour *La Longue Marche à travers la théorie de Galois* (1995, 1 584 pages) ; L. Schneps et P. Lochak pour l'*Esquisse d'un programme* (313 pages) ; P. et J. Blass pour les notes préparatoires à EGA V (260 pages). L'équipe de Montpellier qui a catalogué le fonds (S. Dikoff, H. Rodriguez, F. Troilo) complète ce groupe, soit dix personnes. Elles n'ont pas travaillé en même temps, et le corpus n'occupait qu'une partie de leur temps. Si l'on suppose qu'il en a occupé 10 à 50 % pendant leurs années de travail, l'empreinte professionnelle qui lui revient est de 2 à 25 t par an, autour de 7 t au milieu géométrique de la fourchette.

Avec ces hypothèses, la comparaison porte sur des ordres de grandeur, et ses fourchettes sont larges. Les trois mois du projet (0,11 t au centre) font quelques pour cent d'une année de chercheur, et entre 0,3 % et la moitié environ dans les cas extrêmes. Au rythme des semaines mesurées, le projet émettrait environ 0,6 t par an (0,1 à 3,7 t), soit à peu près un dixième de l'empreinte du groupe consacrée au corpus prise au centre ; les extrêmes vont de 0,4 % à près du double. Si l'on compte la fabrication du matériel, comme dans le recoupement Mistral, ces parts sont multipliées par cinq à neuf. La figure 4 montre ces fourchettes côte à côte.

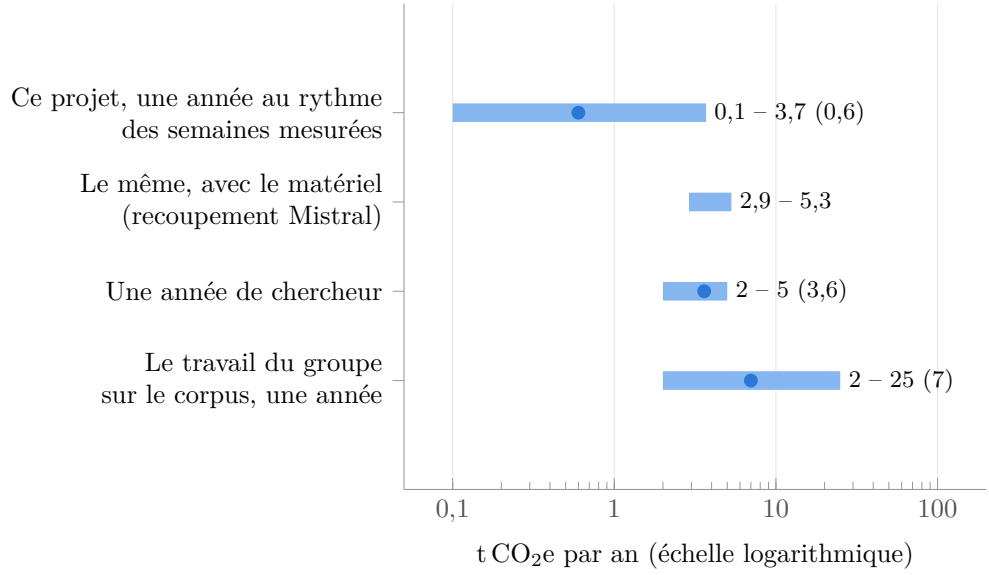


FIGURE 4 – L'empreinte du projet à son rythme actuel, à côté de l'empreinte professionnelle des chercheurs. Le point d'une année de chercheur est la moyenne de 3,6 t par membre de laboratoire trouvée par Mariette et al. (2022) ; celui du groupe est le milieu géométrique de sa fourchette. Les fourchettes reposent sur des hypothèses (dix personnes, 10 à 50 % de leur temps). La comparaison porte sur des ordres de grandeur ; elle ne mesure pas la valeur du travail.

Divisée par les 9 414 pages, l'inférence du projet entier donne environ 12 g CO_2e par page (2 à 120 g). C'est un majorant pour la seule transcription, puisqu'une partie du calcul est allée aux lectures modernisées, aux preuves Lean et aux articles. Une transcription experte à la main, à un rythme supposé de deux à cinq pages par jour et d'environ 200 jours de travail par an, porterait 2 à 12 kg par page si l'on y imputait toute l'empreinte professionnelle de la personne qui transcrit. [**À vérifier : le rythme, à demander aux éditeurs**]. Les deux chiffres ne doivent pas se lire comme un rapport. Le chiffre humain impute des déplacements, des bâtiments et des achats qui servent à tout le travail d'un chercheur ; ce n'est pas le coût de la transcription en tant que telle. Et les deux ne sont pas le même produit. Une page lue par la machine est une première lecture, non vérifiée hormis les citations que l'auteur a collationnées ; une édition humaine est un texte vérifié. La lecture par la machine prépare le travail humain : quelqu'un doit encore vérifier chaque page, si bien que son coût s'ajoute à celui d'une édition. Ces chiffres ne disent pas que le travail humain serait trop lent, et ils ne donnent aucune raison de s'en passer.

8 L'effet rebond

Rendre une activité moins chère tend à la faire croître. Pour l'entraînement des modèles, Morand et al. (2026) trouvent que l'énergie et les impacts ont augmenté de façon exponentielle sur une décennie, malgré un matériel plus efficace et une électricité moins carbonée ; les optimisations n'ont pas réduit les impacts, ce qui suggère un effet rebond, et l'efficacité seule ne garantit pas la soutenabilité. Le manifeste issu d'un atelier de Dagstuhl sur la responsabilité de l'informatique face au climat fait le même constat à plus grande échelle : l'informatique améliore surtout l'efficacité et réduit les coûts, ce qui conduit à consommer davantage, et les gains d'efficacité n'ont pas suffi jusqu'ici à freiner les émissions mondiales (Knowles et al., 2025). Lacroux et al. (2026) ajoutent que les effets rebond indirects sont peu étudiés, moins par manque de connaissances que parce que les cadres institutionnels de l'évaluation les laissent de côté.

Ce projet en donne un exemple à petite échelle. La lecture par la machine a été assez bon marché pour qu'on lise tout : 9 414 pages en trois mois, presque deux fois les 5 129 pages des éditions faites à la main. Sans la machine, ces pages n'auraient pas été transcrites en trois mois, et rien n'indique qu'elles l'auraient été bientôt. Le calcul n'a donc pas remplacé un travail qui se serait fait autrement ; il a servi à faire davantage. Les 110 kg ne sont pas une économie par rapport à une édition à la main : ils s'ajoutent à ce qui se serait fait sans eux.

Il faut en tirer deux conséquences pour la sobriété. La première est qu'un coût par page faible ne suffit pas à justifier un usage : ce qui compte est le total, et le total croît avec ce qu'on décide de lire. La seconde est que le choix de ce qu'on lit par la machine doit être fait pour lui-même. Une première lecture de tout le fonds a une valeur, celle d'un inventaire du contenu, qui aide à choisir ce qu'il faudra éditer avec soin. Le même calcul, refait à chaque reconstruction du site ou à chaque relecture d'une transcription déjà faite, n'en a guère.

Le projet n'a pas eu jusqu'ici de règle de sobriété proprement dite. Depuis le 18 octobre, l'auteur fixe un plafond hebdomadaire d'usage, mais pour partager le quota de son abonnement avec ses autres travaux, et ce plafond a été levé ou relevé à deux reprises. Haiku 5.5, le plus petit des trois modèles, a servi à recompter les jetons de cet article. Ce que ces choix ont changé ne se mesure pas avec ces données : les historiques des sous-agents d'avant le 1er novembre ont été effacés (section 6), et une comparaison des semaines d'avant et d'après en serait faussée. Les mesures possibles, des sessions plus courtes, des modèles plus petits pour les tâches simples, moins de reconstructions du site, seront discutées dans la section sur l'IA frugale prévue pour les deux livres du projet (ticket #116 du dépôt, `https://github.com/Commutator-IO/grothendieck-project/issues/116`), dont cet article fournit la base chiffrée. [**À vérifier : dire quelles limites l'auteur retient désormais**].

9 Limites

L'énergie par jeton d'un modèle de pointe n'est pas publiée, et c'est la principale source d'incertitude. Le prix est un indicateur grossier du calcul (section 3). Moins de la moitié de la période a été mesurée ; le reste est extrapolé à partir de l'activité du dépôt. Dans la fenêtre même, les jetons de 478 sous-agents dont l'historique a été effacé ne sont qu'estimés, et l'estimation principale ne les compte pas (section 6). La répartition par activité repose sur un classement heuristique. La fabrication du matériel n'intervient que par un recoupement, et l'entraînement est laissé de côté. L'eau aussi : les deux chiffres publiés par réponse diffèrent de plus d'un facteur cent (0,26 mL pour la requête Gemini médiane, 45 mL pour une réponse Mistral de 400 jetons) (Elsworth et al., 2025 ; Mistral AI, 2025), et nous n'avons pas de raison de choisir entre eux. Les coefficients de l'intégration continue sont des moyennes publiées pour un fournisseur, non des mesures de ces machines.

10 Conclusion

[À vérifier : brouillon de conclusion, à réécrire par l'auteur]

Trois mois de lecture d'un fonds d'archives mathématiques par un modèle de langage ont coûté, selon notre estimation, autour de 110 kg CO_2e, dans une fourchette qui va de 15 kg à 1,1 t, et sans doute plusieurs fois plus si l'on compte la fabrication des serveurs. C'est l'ordre de grandeur de quelques pour cent de l'empreinte professionnelle annuelle d'un chercheur. Ce n'est pas rien, et ce n'est pas non plus ce qui décide à lui seul de la légitimité d'un tel projet.

La plus grande part de la dépense tient à la manière de travailler plus qu'au nombre de pages : un agent relit à chaque tour un contexte de plusieurs centaines de milliers de jetons pour en écrire quelques centaines. C'est là que se trouvent les marges de sobriété, et elles dépendent de choix que l'utilisateur peut faire : la longueur des sessions, la taille du modèle, la fréquence des reconstructions.

La comparaison avec le travail des éditeurs ne mesure pas la valeur de leur travail, et la lecture par la machine ne le remplace pas : elle s'y ajoute. Elle a aussi conduit à lire beaucoup plus qu'on ne l'aurait fait sans elle, ce qui est le mécanisme même de l'effet rebond. La question qui reste, et que ce chiffre ne tranche pas, est de savoir si ce qu'on a lu en plus valait ce qu'il a coûté.

Déclaration sur l'usage de l'intelligence artificielle

Humanités numériques ne publie pas de politique sur l'usage de l'intelligence artificielle. Sa charte éthique réserve la qualité de coauteur aux « personnes ayant contribué d'une manière significative » ; aucun modèle n'est donc nommé parmi les auteurs, et l'auteur assume seul la responsabilité du texte. Nous décrivons ici tout ce que les modèles ont fait.

Le projet étudié repose sur des modèles de langage de l'entreprise Anthropic (Claude Opus 5.5, Sonnet 5.5 et Haiku 5.5), utilisés au moyen de l'outil Claude Code : ils ont transcrit les pages manuscrites, rédigé les lectures modernisées, écrit les preuves Lean et préparé les brouillons des articles du projet. Pour le présent article, les mêmes outils ont servi à compter les jetons et les exécutions de l'intégration continue, à faire les calculs et les figures, à rédiger une première version en anglais, à produire un rapport de relecture simulé et une vérification des références, puis à écrire la présente version française. Chaque référence a été vérifiée sur sa notice (Crossref, DataCite, arXiv, HAL ou la page de l'éditeur) avant d'être citée, et seules les affirmations lues dans les sources sont attribuées à leurs auteurs. Les choix de méthode, les hypothèses et les conclusions sont ceux de l'auteur, qui a relu et vérifié l'ensemble. Les calculs de cet article comprennent la consommation de ces usages eux-mêmes, puisqu'ils entrent dans la fenêtre mesurée. [**À vérifier : préciser la part du texte que l'auteur a réécrite lui-même, et vérifier que la revue accepte cette déclaration sous cette forme**].

Bibliographie

Anthropic. Pricing. Documentation de la plateforme Claude, consultée le 7 novembre 2026, 2026. URL `https://platform.claude.com/docs/en/about-claude/pricing`.

Anne Baillot and Anne-Laure Ligozat. Introduction. Sobriété numérique. *Humanités numériques*, 11, 2025. doi: 10.4000/1498x.

David Benaben, Françoise Berthoud, Gaël Guennebaud, Anne-Laure Ligozat, and S. Valcke. Estimation de l'empreinte carbone d'une heure de calcul sur un cœur CPU ou sur un GPU. Rapport méthodologique, HAL hal-04738556, January 2024. URL `https://inria.hal.science/hal-04738556v1`.

Cloud Carbon Footprint. Methodology. Documentation du projet Cloud Carbon Footprint, consultée le 7 novembre 2026, 2026. URL `https://www.cloudcarbonfootprint.org/docs/methodology`.

Marianne De Paepe, Laurent Jeanneau, Jérôme Mariette, Olivier Aumont, and André Estevez-Torres. Purchases dominate the carbon footprint of research laboratories. *PLOS Sustainability and Transformation*, 3(7):e0000116, 2024. doi: 10.1371/journal.pstr.0000116.

Cooper Elsworth, Keguo Huang, David Patterson, Ian Schneider, Robert Sedivy, Savannah Goodman, Ben Townsend, Parthasarathy Ranganathan, Jeff Dean, Amin Vahdat, Ben Gomes, and James Manyika. Measuring the environmental impact of delivering AI at Google scale. arXiv:2508.15734, 2025.

GitHub. GitHub-hosted runners. GitHub Docs, consulté le 7 novembre 2026, 2026. URL `https://docs.github.com/en/actions/concepts/runners/github-hosted-runners`.

Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B. Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. arXiv:2001.08361, 2020.

Bran Knowles, Vicki L. Hanson, Christoph Becker, Mike Berners-Lee, Andrew A. Chien, Benoit Combemale, Vlad Coroamă, Koen De Bosschere, Yi Ding, Adrian Friday, Boris Gamazaychikov, Lynda Hardman, Simon Hinterholzer, Mattias Höjer, Lynn Kaack, Lenneke Kuijer, Anne-Laure Ligozat, Jan Tobias Muehlberg, Yunmook Nah, Thomas Olsson, Anne-Cécile Orgerie, Daniel Pargman, Birgit Penzenstadler, Tom Romanoff, Emma Strubell, Colin Venters, and Junhua Zhao. Climate change: What is computing's responsibility? (Dagstuhl Perspectives Workshop 25122). *Dagstuhl Manifestos*, 11(1):1–18, 2025. doi: 10.4230/DagMan.11.1.1.

Damien Lacroux, Aurélie Bugeau, and Anne-Laure Ligozat. The indirect rebound effects of AI as undone science: philosophical reflection on two structural causes. In *Undone Computer Science, Luxembourg, March 2026*, 2026. URL `https://hal.science/hal-05624399v1`. Résumé étendu, HAL hal-05624399.

Anne-Laure Ligozat, Julien Lefèvre, Aurélie Bugeau, and Jacques Combaz. Unraveling the hidden environmental impacts of AI solutions for environment: Life cycle assessment of AI solutions. *Sustainability*, 14(9):5172, 2022. doi: 10.3390/su14095172.

Anne-Laure Ligozat, Christophe Brun, Benjamin Demirdjian, Guillaume Gouget, Emilie Jardé, Arnaud Mialon, Anne-Sophie Mouronval, Laurent Pagani, and Laure Vieu. Setting climate targets: The case of higher education and research. Preprint, bioRxiv; HAL hal-04505199, 2024.

Alexandra Sasha Luccioni, Sylvain Viguier, and Anne-Laure Ligozat. Estimating the carbon footprint of BLOOM, a 176B parameter language model. *Journal of Machine Learning Research*, 24(253):1–15, 2023. URL `https://hal.science/hal-04288059v1`.

Sasha Luccioni, Yacine Jernite, and Emma Strubell. Power hungry processing: Watts driving the cost of AI deployment? In *The 2024 ACM Conference on Fairness, Accountability, and Transparency (FAccT '24)*, pages 85–99. ACM, 2024. doi: 10.1145/3630106.3658542.

Jérôme Mariette, Odile Blanchard, Olivier Berné, Olivier Aumont, Julian Carrey, Anne-Laure Ligozat, Emmanuel Lellouch, Philippe-Emmanuel Roche, Gaël Guennebaud, Joel Thanwerdas, Philippe Bardou, Gérald Salin, Elise Maigne, Sophie Servan, and Tamara Ben-Ari. An open-source tool to assess the carbon footprint of research. *Environmental Research: Infrastructure and Sustainability*, 2 (3):035008, 2022. doi: 10.1088/2634-4505/ac84a4.

Mistral AI. Our contribution to a global environmental standard for AI. Actualités de Mistral AI, 22 juillet 2025, 2025. URL `https://mistral.ai/news/our-contribution-to-a-global-environmental-standard-for-ai`.

Clément Morand, Anne-Laure Ligozat, and Aurélie Névéol. The environmental impacts of language model training keep rising: Now is the time to catch impacts on the rebound. In *EMNLP 2026 – Conference on Empirical Methods in Natural Language Processing*, 2026. URL `https://hal.science/hal-04839926v6`. HAL hal-04839926, version 6, 24 octobre 2026.

Pratyush Patel, Esha Choukse, Chaojie Zhang, Aashaka Shah, Íñigo Goiri, Saeed Maleki, and Ricardo Bianchini. Splitwise: Efficient generative LLM inference using phase splitting. In *2024 ACM/IEEE 51st Annual International Symposium on Computer Architecture (ISCA)*, pages 118–132. IEEE, 2024. doi: 10.1109/ISCA59077.2024.00019.

Reiner Pope, Sholto Douglas, Aakanksha Chowdhery, Jacob Devlin, James Bradbury, Jonathan Heek, Kefan Xiao, Shivani Agrawal, and Jeff Dean. Efficiently scaling transformer inference. In *Proceedings of Machine Learning and Systems 5 (MLSys 2023)*, 2023. URL `https://proceedings.mlsys.org/paper_files/paper/2023/hash/c4be71ab8d24cdfb45e3d06dbfca2780-Abstract-mlsys2023.html`. arXiv:2211.05102.

The Shift Project. Pour une sobriété numérique. Rapport, The Shift Project, October 2018. URL `https://theshiftproject.org/publications/pour-une-sobriete-numerique/`.

The Shift Project. Intelligence artificielle, données, calculs : quelles infrastructures dans un monde décarboné ? Rapport final, The Shift Project, October 2025. URL `https://theshiftproject.org/publications/intelligence-artificielle-centres-de-donnees-rapport-final/`.

Josh You. How much energy does ChatGPT use? Gradient Updates, Epoch AI, February 2025. URL `https://epoch.ai/gradient-updates/how-much-energy-does-chatgpt-use`.